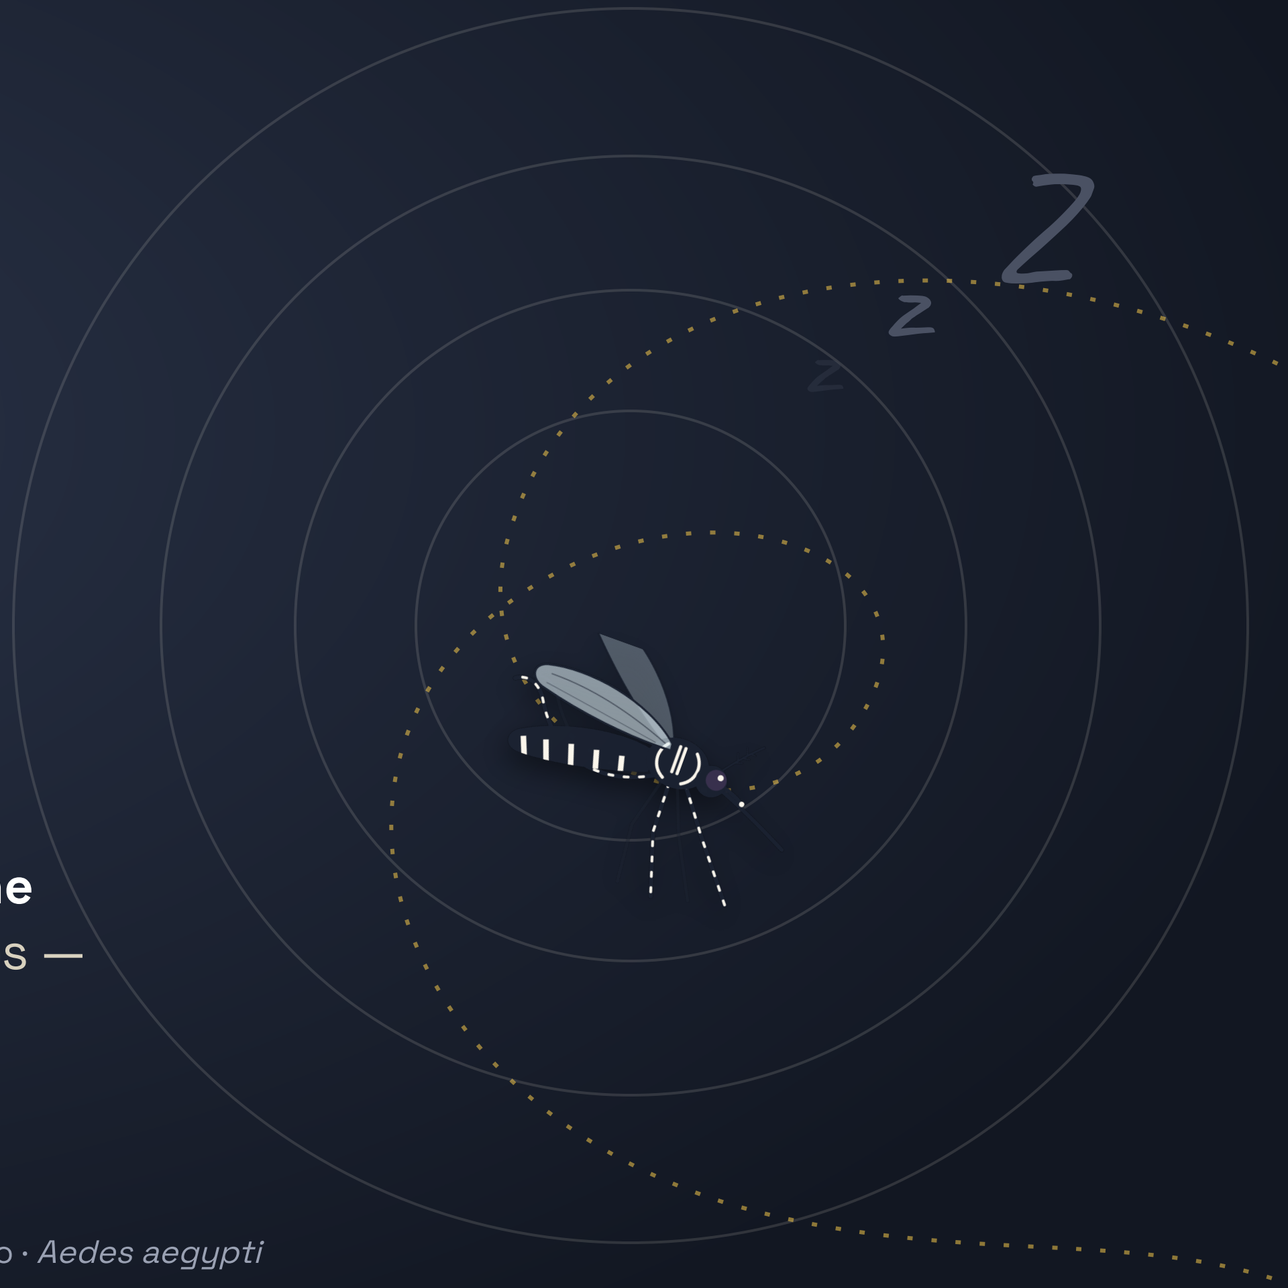
IFSC · IA na Eletrônica · 2026

Zzzz... é *Aedes*?



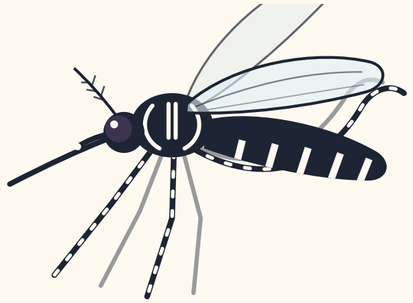
Como trabalha um desenvolvedor de **Machine Learning**: ferramentas, processo e resultados — ensinando uma máquina a *ouvir* mosquitos.

Luiz Eduardo do Nascimento Ciarallo

Projeto `mosquito-wingbeat` · detector ternário: ruído · outro mosquito · *Aedes aegypti*

o problema

Por que ouvir mosquitos?



Um vetor perigoso

O *Aedes aegypti* transmite **dengue, zika e chikungunya**. Saber **onde e quando** ele aparece orienta o combate.



Microfone barato

Uma armadilha com microfone pode monitorar **24 h por dia**, sem ninguém olhar lupa. O som vira dado.



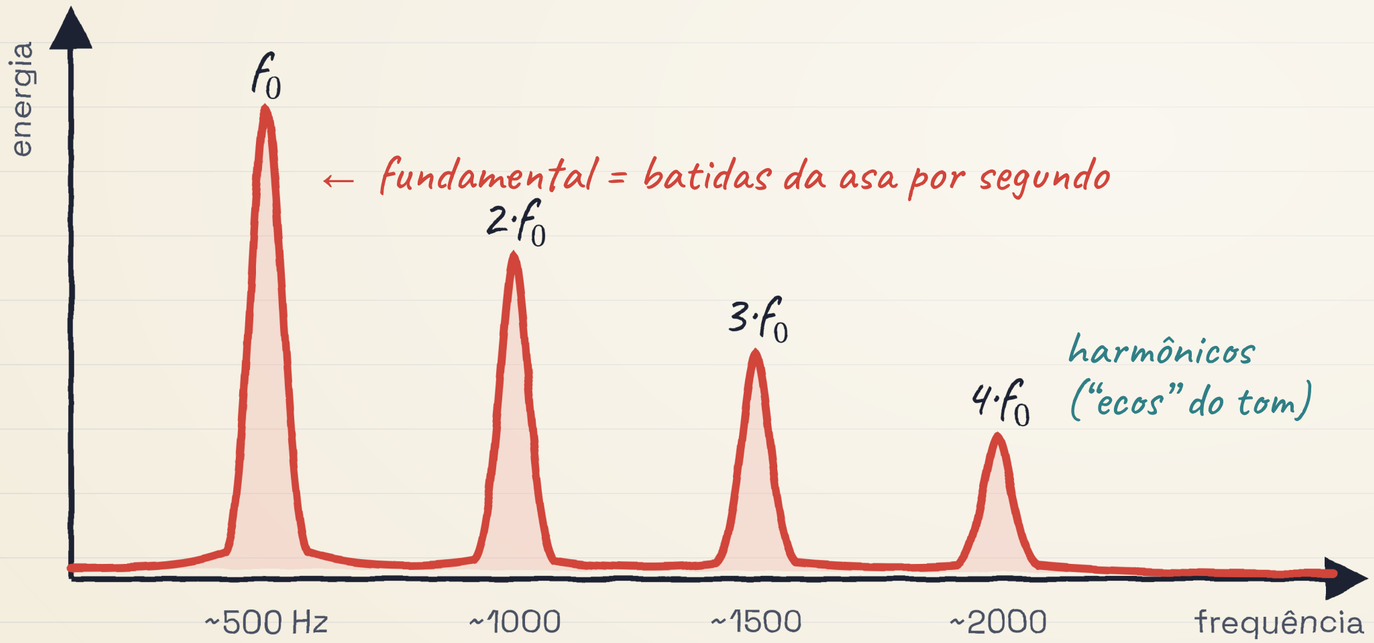
~500 batidas de asa por segundo

Cada espécie “canta”

O zumbido é o **batimento de asa**: centenas de Hz, com harmônicos. A ideia é reconhecer a espécie **pelo tom**.

a física do zumbido

O canto: um **tom** e seus **ecos**



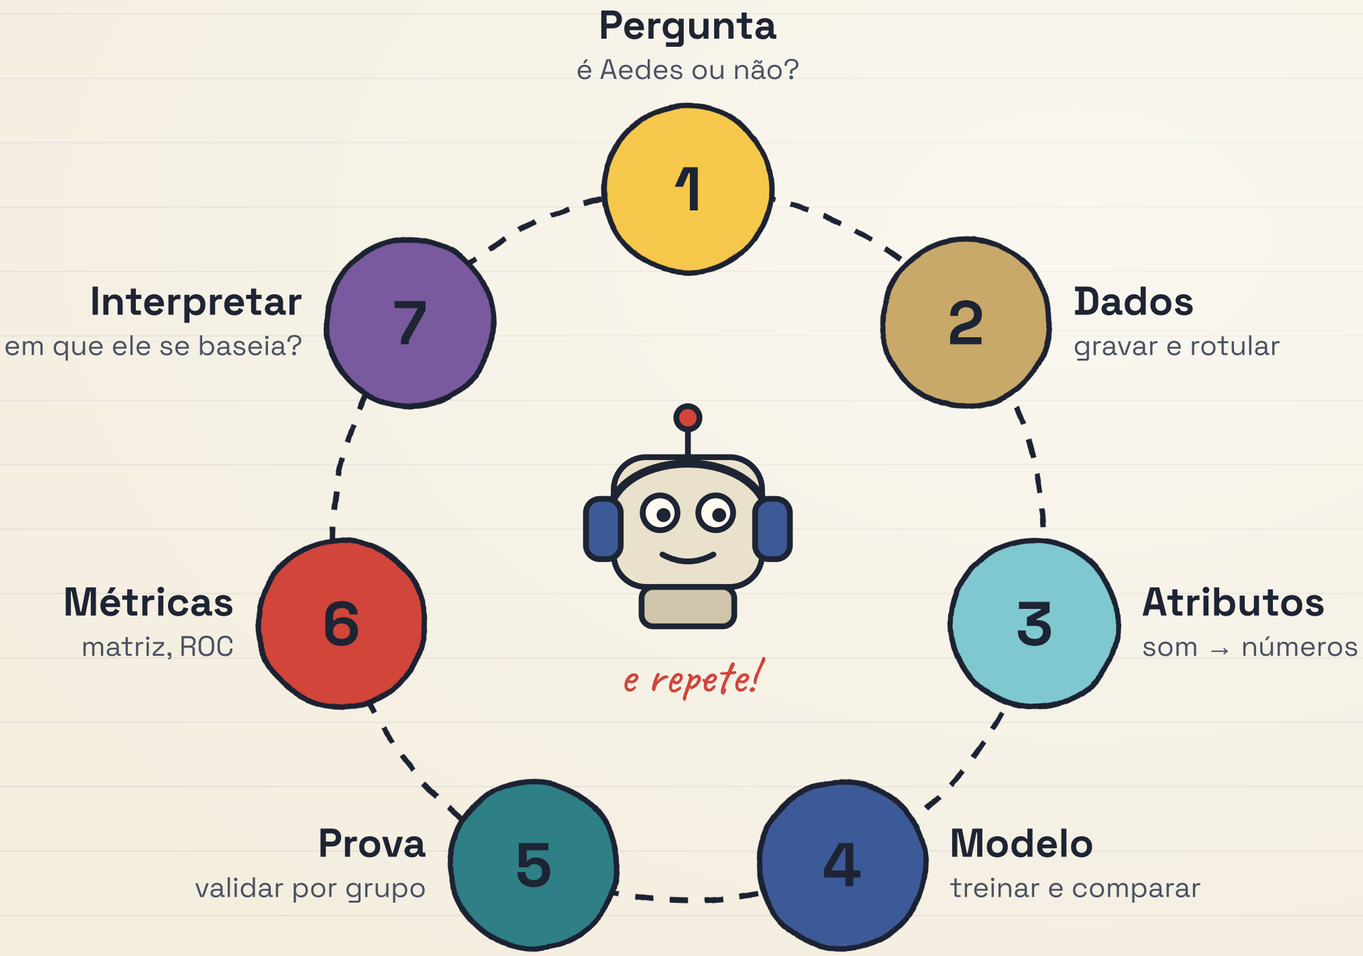
como medimos f_0

```python
# candidatos de 250 a 1000 Hz
cand = np.arange(250, 1001)
# soma harmônica (média dos logs)
harm = np.exp(sum(np.log(amp(k*cand))
          for k in range(1, 4)) / 3)
f0 = cand[np.argmax(harm)]  # o "tom"
```

⚠ Mas os tons **se sobrepõem:** Aedes aparece de ~300 a ~900 Hz, outras espécies de 250 a 1000 Hz. Macho ≠ fêmea. Só o tom não basta.

o trabalho de um dev de ML

Um projeto de ML é um ciclo



Na prática, a maior parte do tempo vai em dados e em provar que funciona — não em escolher o modelo.

Cada volta no ciclo responde a uma pergunta: **"o resultado é real ou o modelo está colando?"** Se a interpretação mostra algo estranho, voltamos aos dados.

é esse ciclo que vamos percorrer com o detector de mosquito

a caixa de ferramentas

As ferramentas do dia a dia

Python
A linguagem de quase todo projeto de ML. Legível e com bibliotecas para tudo.

NumPy · pandas
Tabelas e matrizes de números: cada gravação vira uma linha com 80 colunas.

SciPy · PyTorch
Sinais (espectrograma mel) e as **redes neurais** (MLP e CNN).

scikit-learn
Os modelos (SVM, árvores), a validação cruzada e as métricas, prontos para usar.

Matplotlib
Gráficos: espectros, matriz de confusão, curva ROC. Olhar antes de acreditar.

VS Code · Jupyter
Editor e notebooks: código, texto e gráfico na mesma página.

Git · GitHub
Histórico de cada mudança: dá para voltar atrás e reproduzir um resultado.

Assistentes de IA
Claude Code, Codex e Hermes: escrevem e rodam código comigo. (Volto nisso no fim.)

Arduino
E do lado da eletrônica: **Arduino Nano 33 BLE Sense** com microfone embutido, para gravar e testar o detector no mundo real.

os dados

Quem ensina o quê

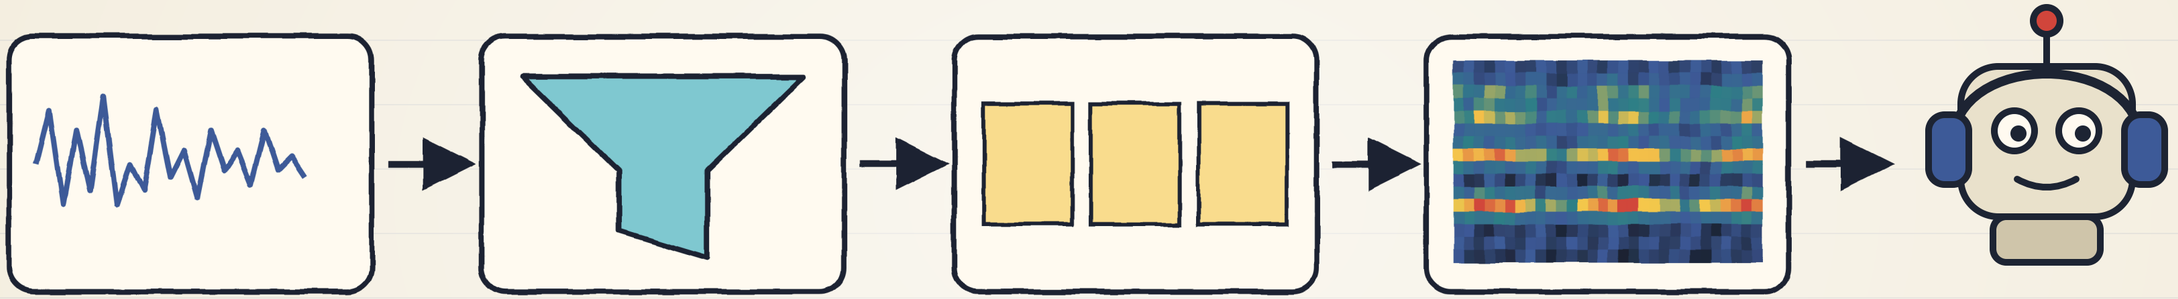
Um modelo de ML aprende **por exemplos rotulados**. A escolha dos exemplos é a primeira decisão de projeto:

1. **Aedes** de dois datasets grandes, **Torres** e **Funchal**: 2.167 exemplos.
2. Os outros datasets ensinam o que **não é Aedes**: 3.050 outros mosquitos e 426 ruídos.
3. Cada exemplo guarda **de onde veio** (fonte e aparelho). Isso vai servir para normalizar e para montar a prova.



como a máquina "ouve"

Do zumbido aos **números**



áudio bruto
.wav, .mp4, celular...

espectrograma mel
energia por faixa

16 bandas até 4 kHz
onde mora o zumbido

5 resumos × 16
= 80 números

modelo
ruído · outro · Aedes

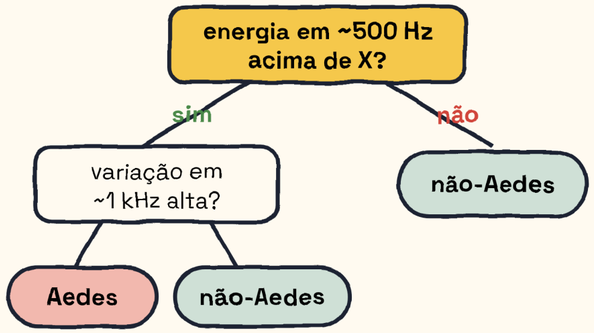
de espectrograma a 80 números

```
z = db[:, :, bandas_ate_4khz]      # mel em dB
z = z - z.max()                    # relativo ao pico
X = np.concatenate([z.mean(1), z.std(1),
     *np.quantile(z, [.1, .5, .9], axis=1)])
# 16 bandas × 5 resumos = 80 atributos
```

*A escala **mel** imita o ouvido. Para cada faixa, resumimos como a energia se comporta no tempo: **média**, **variação** e **percentis**. O batimento de asa (~400–900 Hz) cai em várias faixas.*

os modelos de ML

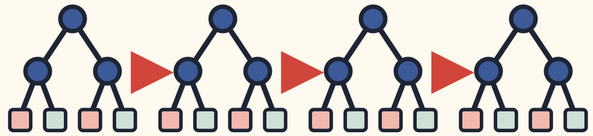
Árvores que fazem perguntas



Árvore de decisão

Uma sequência de perguntas sim/não sobre os 80 números. O treino escolhe **quais perguntas** e **quais limites** separam melhor as classes.

uma depois da outra, corrigindo erros

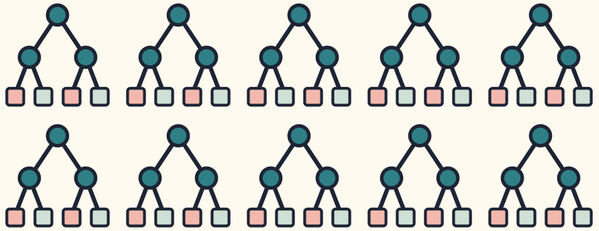


árvore 1 + 2 + 3 + … + 300

HistGB (boosting)

Árvores pequenas **em fila**: cada nova árvore foca nos **erros** das anteriores. A soma de muitas perguntas fracas vira um modelo forte.

todas ao mesmo tempo, depois votam



média de 400 votos

Extra Trees (floresta)

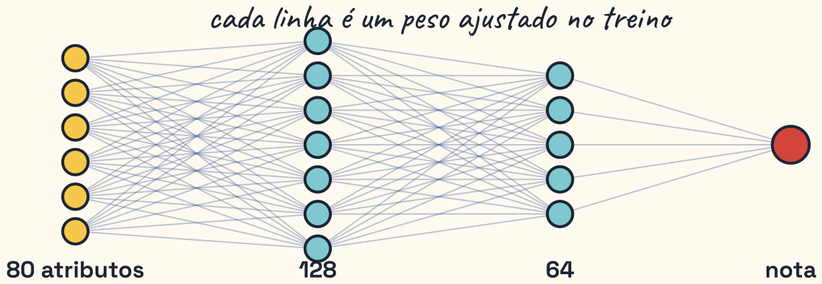
Centenas de árvores **independentes**, com cortes sorteados. Cada uma vota; a média é mais estável que qualquer árvore sozinha.

no scikit-learn

```
hgb = HistGradientBoostingClassifier(learning_rate=0.05, max_iter=300, max_leaf_nodes=15)
et  = ExtraTreesClassifier(n_estimators=400, min_samples_leaf=2)
p_aedes = (hgb.predict_proba(X)[:, 1] + et.predict_proba(X)[:, 1]) / 2   # média dos dois
```

e as redes neurais?

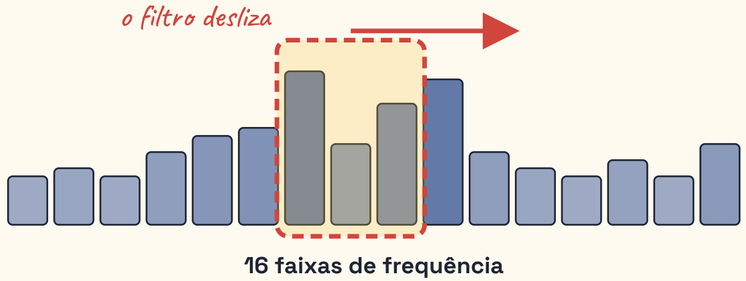
Redes neurais: MLP e CNN



MLP (perceptron multicamadas)

Camadas de “neurônios”: cada um soma os 80 números com **pesos** e passa por uma função (ReLU). O treino ajusta os pesos para errar menos.

```
mlp = nn.Sequential(
    nn.Linear(80, 128), nn.ReLU(),   # camada 1
    nn.Linear(128, 64), nn.ReLU(),   # camada 2
    nn.Linear(64, 1))                  # nota de Aedes
```



CNN (rede convolucional)

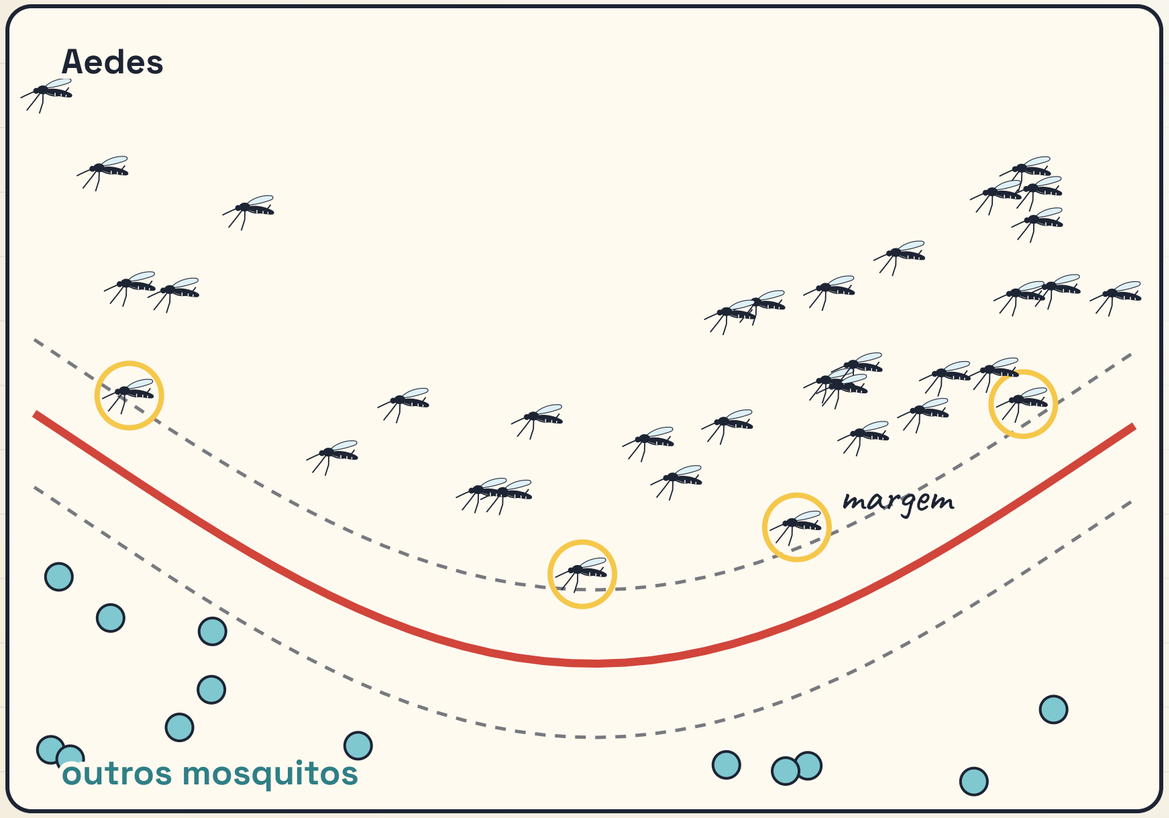
Um **filtro** pequeno desliza pelas 16 faixas de frequência procurando padrões (como “pico + harmônico”), em qualquer posição.

```
cnn = nn.Sequential(
    nn.Conv1d(5, 32, kernel_size=3), nn.ReLU(),  # filtros
    nn.Conv1d(32, 64, kernel_size=3), nn.ReLU(),
    nn.AdaptiveMaxPool1d(1), nn.Flatten(),
    nn.Linear(64, 1))                          # nota
```

```
for epoca in range(60):   # treino: mostrar os exemplos várias vezes e corrigir os pesos
    perda = binary_cross_entropy(rede(X_lote), y_lote); perda.backward(); otimizador.step()
```

o modelo final

SVM: a fronteira com mais folga



○ *amarelo = vetores de suporte (os que definem a fronteira)*

Como funciona

A SVM (*máquina de vetores de suporte*) procura a linha que separa as classes deixando a **maior margem** possível. Só os pontos na beira da margem — os **vetores de suporte** — definem a fronteira.

O truque do kernel RBF

Com 80 números, uma reta não basta. O kernel RBF mede a **semelhança** entre gravações e permite fronteiras **curvas**.

```
from sklearn.svm import SVC
svm = SVC(kernel='rbf', C=1.0, probability=True)
svm.fit(X_treino, y_treino, sample_weight=pesos)
p_aedes = svm.predict_proba(X_teste)[:, 1]
```

*A SVM mede **distâncias**, então precisa de atributos na mesma escala — exatamente o que a normalização por fonte entrega.*

a regra de ouro

Não deixar o modelo colar na prova

✗ dobras por arquivo



o mesmo celular aparece nos dois lados

✓ dobras por pote (cluster)



a prova é de um aparelho nunca visto

o "fiscal" da prova

```
sg = StratifiedGroupKFold(n_splits=5)
for tr, te in sg.split(X, y, groups=cluster):
    assert not (set(cluster[tr])
                & set(cluster[te])), \
        "cluster leakage"
```

Se o mesmo aparelho aparece no treino e na prova, o modelo pode **decorar o aparelho** e a nota fica inflada.

Grupo = gravação, indivíduo ou aparelho. **5 dobras**, repetidas **3 vezes** com sorteios diferentes.

como foi feito

Três ajustes no treino



cada aparelho tem seu "sotaque"

1 Normalizar por fonte

Cada fonte é centralizada nela mesma: some o "sotaque" do microfone, fica o mosquito.

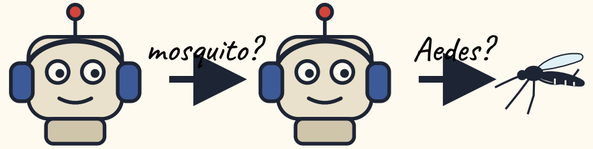
```
for fonte in fontes:
    m = origem == fonte
    X[m] = (X[m] - X[m].mean(0)) \
           / X[m].std(0)
```



2 Pesos por fonte

Uma fonte com 1.800 exemplos não pode "gritar" mais alto que uma com 20. Cada fonte pesa igual dentro da classe.

```
for fonte in fontes_da_classe:
    m = (y == c) & (origem == fonte)
    w[m] = 1 / m.sum() / n_fontes
modelo.fit(X, y, sample_weight=w)
```



3 Dois estágios

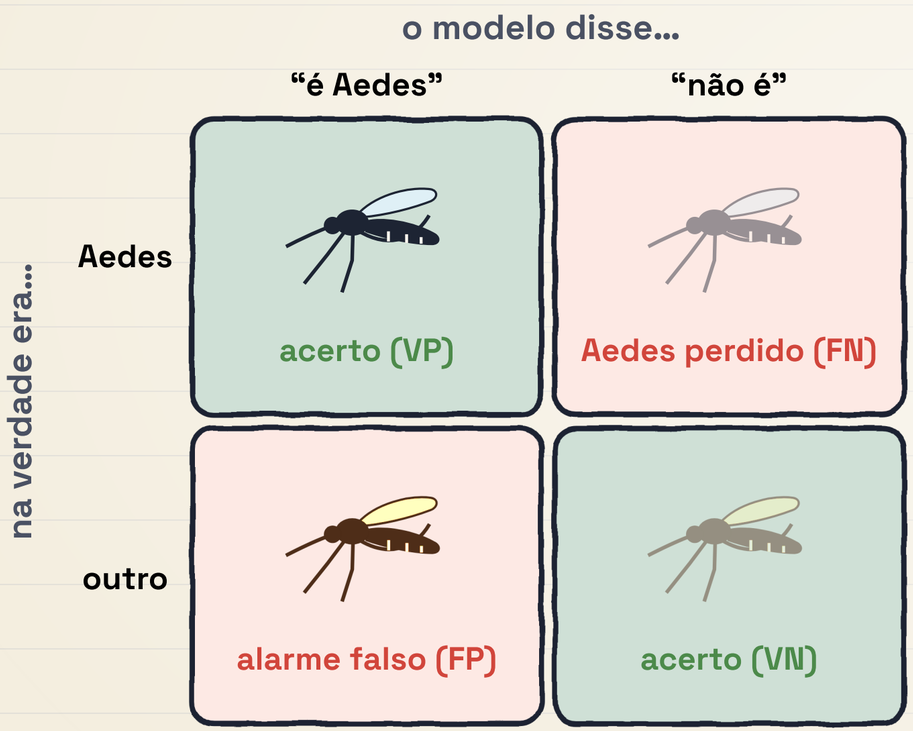
Primeiro: **tem mosquito?** Depois, só entre mosquitos: **é Aedes?** Um modelo para cada pergunta.

```
p_m = svm_mosquito.predict_proba(X)[:, 1]
p_a = svm_aedes.predict_proba(X)[:, 1]

p = [1 - p_m,           # ruído
     p_m * (1 - p_a),   # outro
     p_m * p_a]         # Aedes
```

como medir

Acurácia não basta: três perguntas



a “matriz de confusão”

Precisão = VP / (VP + FP)

Quando o modelo apita “Aedes”, com que frequência acerta?

Detecção (recall) = VP / (VP + FN)

De todos os Aedes que existiam, quantos ele encontrou?

AUROC

Sorteie um Aedes e um não-Aedes: qual a chance de o Aedes ganhar nota maior? **0,5 = moeda**, 1 = perfeito. Não depende do limiar.

```
from sklearn.metrics import precision_score, recall_score, roc_auc_score
precision_score(y, y_pred); recall_score(y, y_pred)
roc_auc_score(y, p_aedes)   # usa a probabilidade, não o rótulo
```

os métodos, em código

Cada método em poucas linhas

1 · boosting

HistGradientBoosting

Árvores pequenas em fila; cada uma corrige os erros da anterior.

```
from sklearn.ensemble import (
    HistGradientBoostingClassifier)
hgb = HistGradientBoostingClassifier(
    learning_rate=0.05, max_iter=300)
hgb.fit(X_treino, y_treino)
p = hgb.predict_proba(X_teste)[:, 1]
```

2 · margem

SVM (modelo final)

Procura a fronteira que separa as classes com a **maior margem**; o kernel RBF deixa a fronteira curva.

```
from sklearn.svm import SVC
svm = SVC(kernel='rbf', C=1.0, probability=True)
svm.fit(X_treino, y_treino, sample_weight=w)
p = svm.predict_proba(X_teste)[:, 1]
```

3 · cascata

Dois estágios

Primeiro “tem mosquito?”, depois, só entre mosquitos, “é Aedes?”.

```
p_mosq  = svm_mosquito.predict_proba(X)[:, 1]
p_aedes = svm_aedes.predict_proba(X)[:, 1]
p_final = p_mosq * p_aedes  # nota de Aedes
```

4 · validação

Validação cruzada por grupo

5 rodadas; em cada uma, aparelhos inteiros ficam fora do treino.

```
from sklearn.model_selection import (
    StratifiedGroupKFold)
cv = StratifiedGroupKFold(n_splits=5)
for tr, te in cv.split(X, y, aparelho):
    modelo.fit(X[tr], y[tr])
    P[te] = modelo.predict_proba(X[te])
```

5 · métricas

Matriz de confusão e AUROC

Comparam o que o modelo disse com o que era de verdade.

```
from sklearn.metrics import (
    confusion_matrix, roc_auc_score)
confusion_matrix(y, y_previsto)  # 3×3
roc_auc_score(y == 2, p_aedes)  # 0,86
```

6 · interpretação

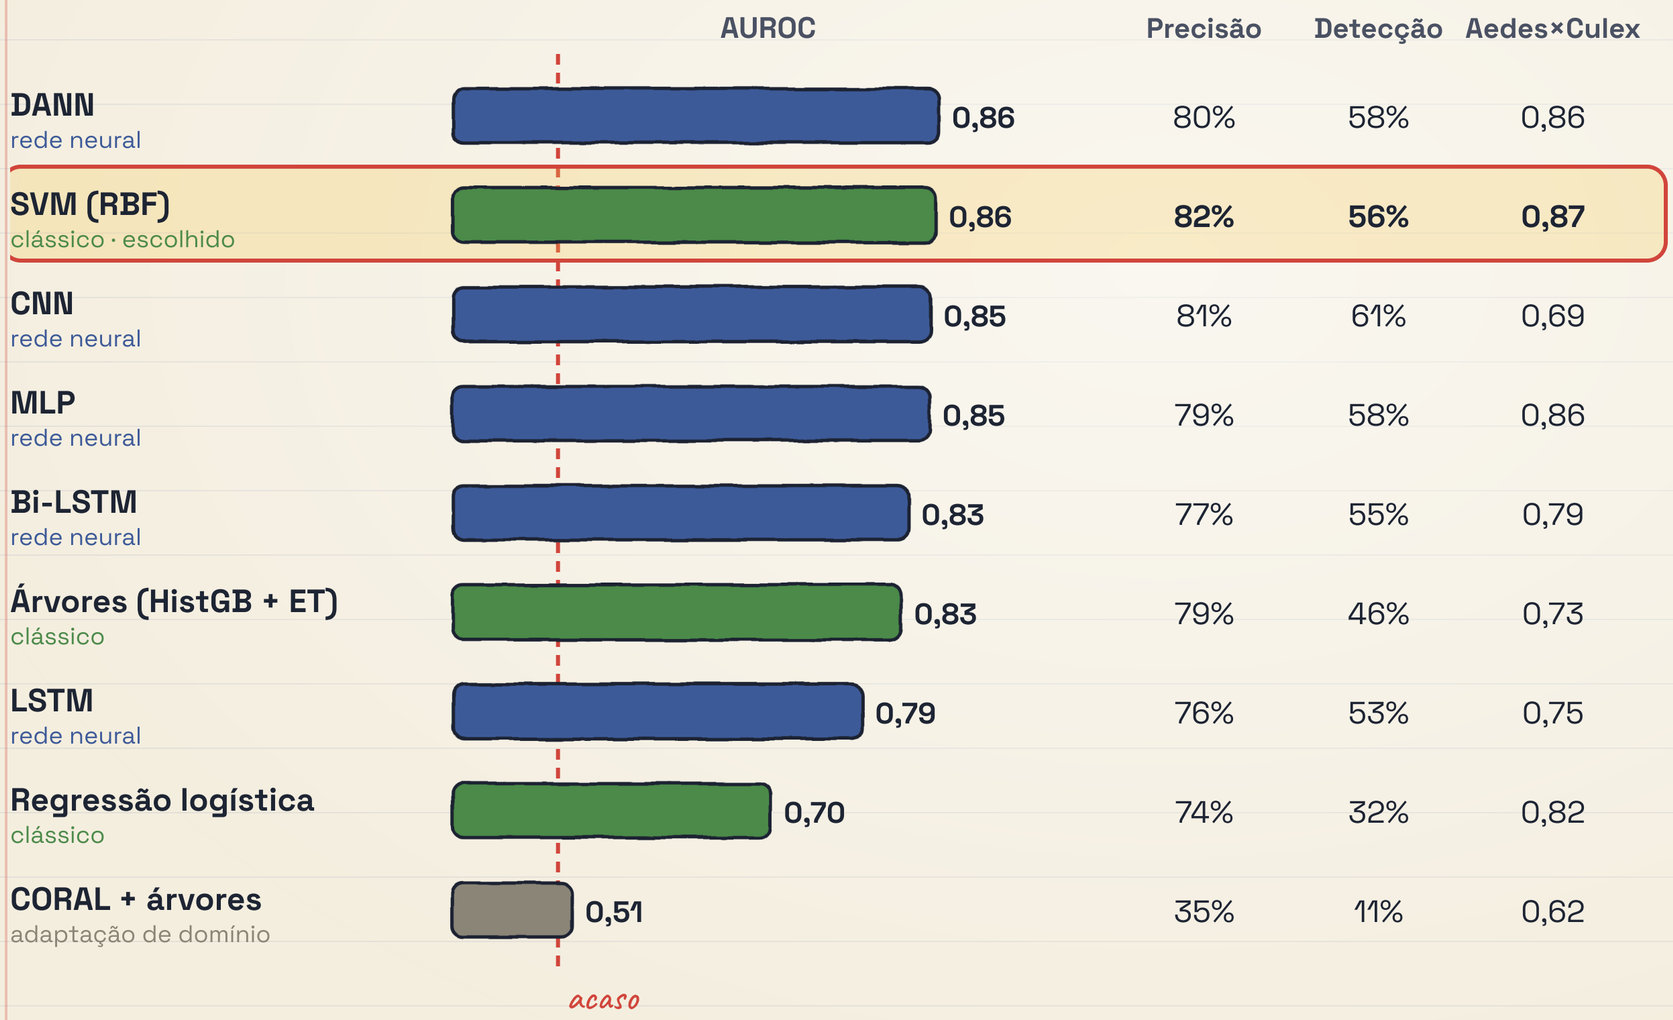
Importância por permutação

Embaralha uma faixa de frequência e mede quanto o modelo piora.

```
Z = X_teste.copy()
Z[:, faixa] = rng.permutation(Z[:, faixa])
p = modelo.predict_proba(Z)[:, 1]
queda = auc_base - roc_auc_score(y, p)
```

qual modelo escolher?

9 modelos, a mesma prova



	AUROC	Precisão	Detecção	Aedes×Culex
DANN rede neural	0,86	80%	58%	0,86
SVM (RBF) clássico · escolhido	0,86	**82%**	**56%**	**0,87**
CNN rede neural	0,85	81%	61%	0,69
MLP rede neural	0,85	79%	58%	0,86
Bi-LSTM rede neural	0,83	77%	55%	0,79
Árvores (HistGB + ET) clássico	0,83	79%	46%	0,73
LSTM rede neural	0,79	76%	53%	0,75
Regressão logística clássico	0,70	74%	32%	0,82
CORAL + árvores adaptação de domínio	0,51	35%	11%	0,62

Escolhemos a SVM

Empatou no topo do AUROC e venceu no que importa na prática: **maior precisão** (82%), **menos alarmes** e a melhor prova Aedes × Culex (0,87).

Redes neurais (DANN, CNN, MLP) chegaram muito perto. As **LSTMs** do artigo do Torres ficaram atrás, e o **CORAL** atrapalhou.

O modelo mais novo não é sempre o melhor: teste vários com a mesma prova e escolha pelos números.

mesmos dados, mesmos ajustes (normalização, pesos, dois estágios), validação por grupo · média de 3 repetições

o resultado, em uma tabela

A matriz de confusão do nosso modelo

era de verdade… \ o modelo disse…	ruído	outro mosquito	Aedes
ruído	**224** 53% da linha	**188** 44% da linha	**14** 3% da linha
outro mosquito	**147** 5% da linha	**2.653** 87% da linha	**250** 8% da linha
Aedes	**51** 2% da linha	**911** 42% da linha	**1.205** 56% da linha

Diagonal = acertos. 1.205 Aedes, 2.653 outros mosquitos e 224 ruídos.

O erro mais comum: 911 Aedes chamados de "outro mosquito". O modelo é **cauteloso**.

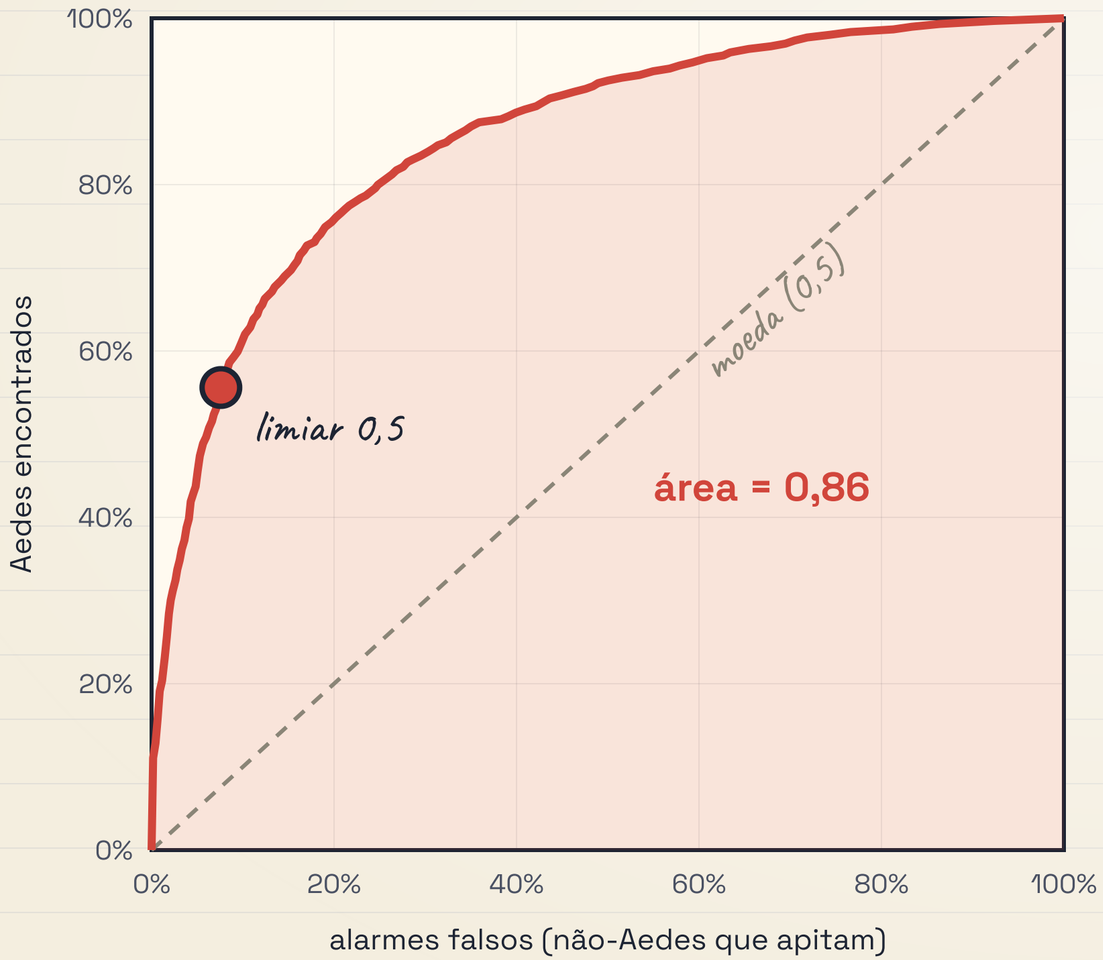
Alarmes falsos são raros: 250 de 3.050 outros mosquitos (8%) e 14 de 426 ruídos (3%).

Precisão = 1.205 / 1.469 = 82%
Detecção = 1.205 / 2.167 = 56%

5.643 gravações, cada uma prevista por um modelo que nunca a viu · limiar 0,5 · modelo: SVM

curvas que ajudam a decidir

A curva ROC



Como ler

Cada ponto é um **limiar** diferente. Para cima = mais Aedes encontrados; para a direita = mais alarmes falsos. A diagonal é o chute (moeda).

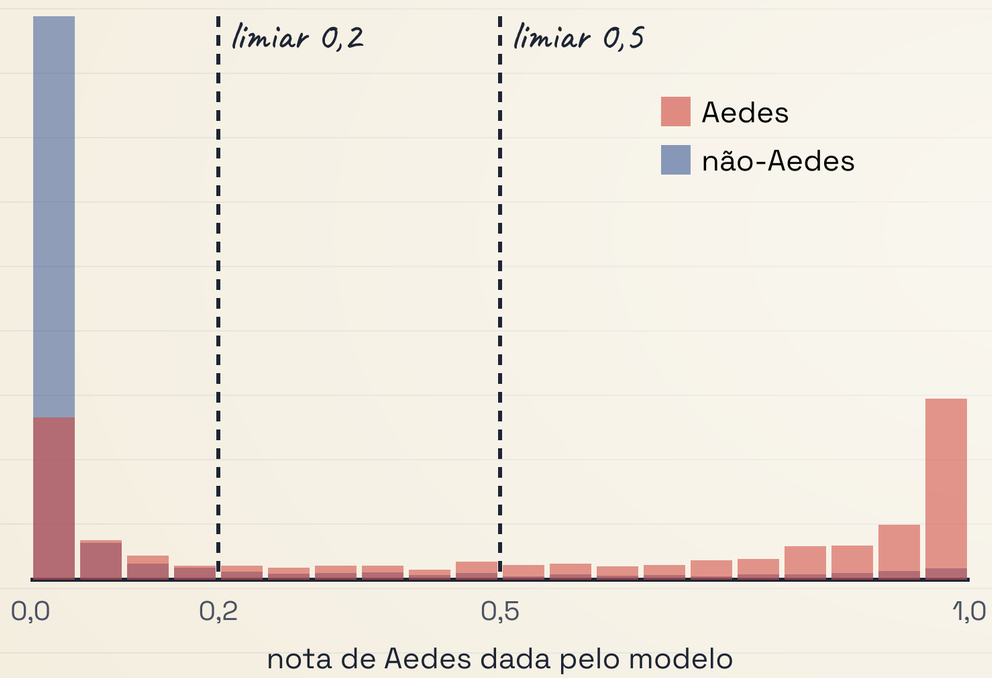
AUROC = 0,86

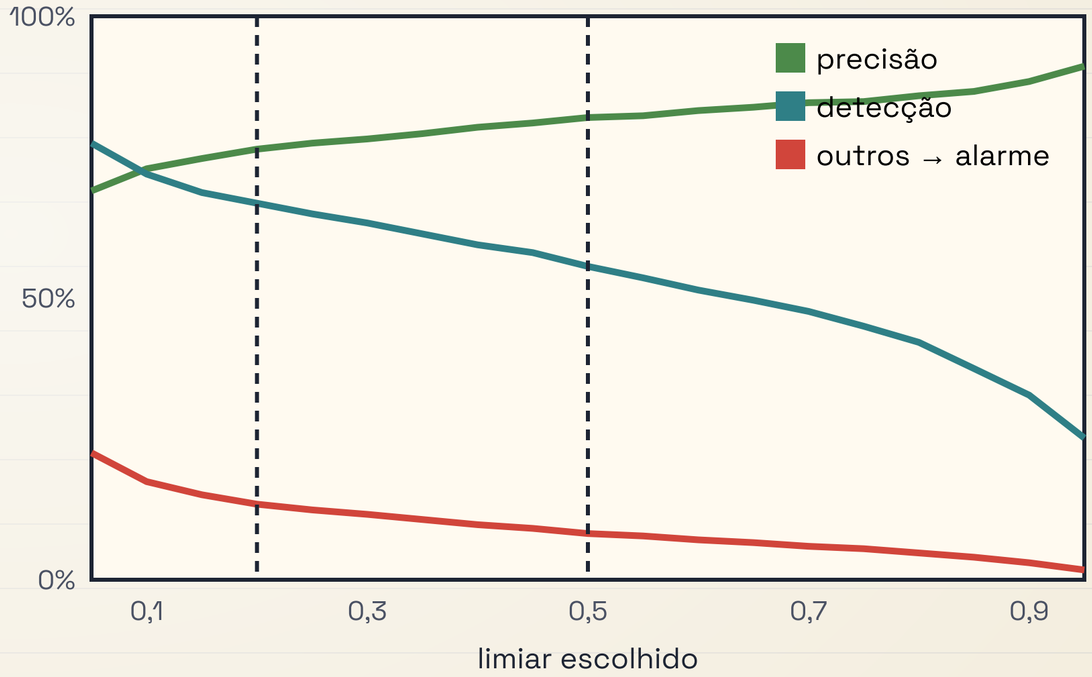
A área sob a curva. Escolhendo um Aedes e um não-Aedes ao acaso, em **86%** das vezes o Aedes recebe nota maior.

O ponto vermelho é o limiar 0,5 que usamos: 56% dos Aedes com só 8% de alarmes falsos.

uma decisão de projeto

Onde cortar a nota?





O modelo não diz "sim/não": dá uma nota de 0 a 1. Quem escolhe o corte somos nós.

Limiar 0,2 (vigilância, não perder Aedes): 67% detectados, 76% de precisão.

Limiar 0,5 (poucos alarmes): 56% detectados, 82% de precisão, 8% dos outros mosquitos apitam.

esquerda: notas que o modelo dá · direita: as três métricas para cada limiar

resultado

Quando apita, costuma ser Aedes

0,86
AUROC para Aedes

82%
dos alertas de Aedes estão certos

8%
dos outros mosquitos viram alarme

3%
dos ruídos viram alarme

De cada 100 alertas de “Aedes”...



82 são Aedes de verdade 18 são outro mosquito ou ruído

e só 8% dos outros mosquitos (3% dos ruídos) disparam alarme

*Quando o modelo diz “é Aedes”, ele acerta **mais de 8 em cada 10** vezes.*

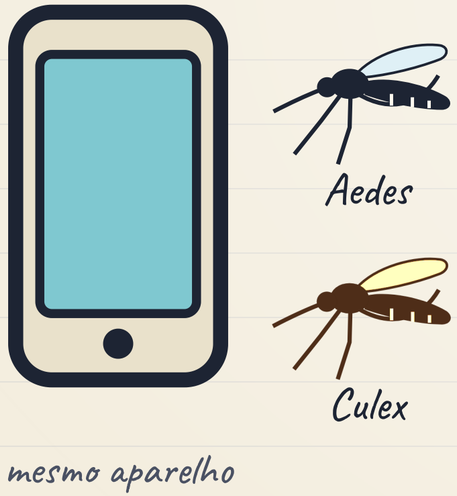
O modelo é **cauteloso**: prefere ficar quieto a dar alarme falso. Detecta **56%** dos Aedes, mas quando apita, costuma estar certo.

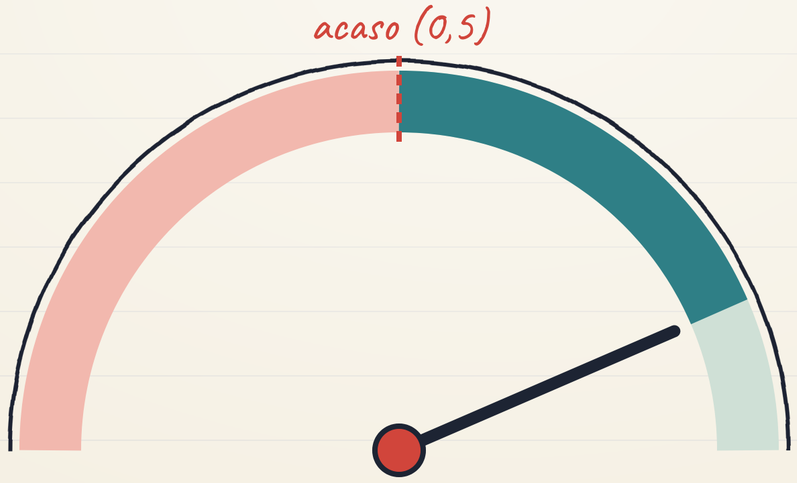
média de 3 repetições · validação cruzada por grupo · modelo: SVM

a prova mais justa

Aedes × *Culex* no mesmo aparelho

Aedes e *Culex* gravados nos **mesmos aparelhos.** Deixamos um aparelho inteiro fora do treino e perguntamos: o modelo separa as duas espécies?





0,87

AUROC Aedes × Culex · aparelho nunca visto

Por que essa prova vale mais

O aparelho é o mesmo para as duas espécies, então **o "sotaque" do microfone não ajuda.** Para acertar, o modelo precisa ouvir o mosquito.

Ainda falta

O modelo só viu Aedes de **dois datasets.** Aedes gravados em **outros aparelhos** ainda não são reconhecidos: o próximo passo é coletar mais fontes.

interpretabilidade

O que o modelo está ouvindo?

As métricas dizem **quanto** o modelo acerta.
A interpretabilidade pergunta **em que ele se baseia**.

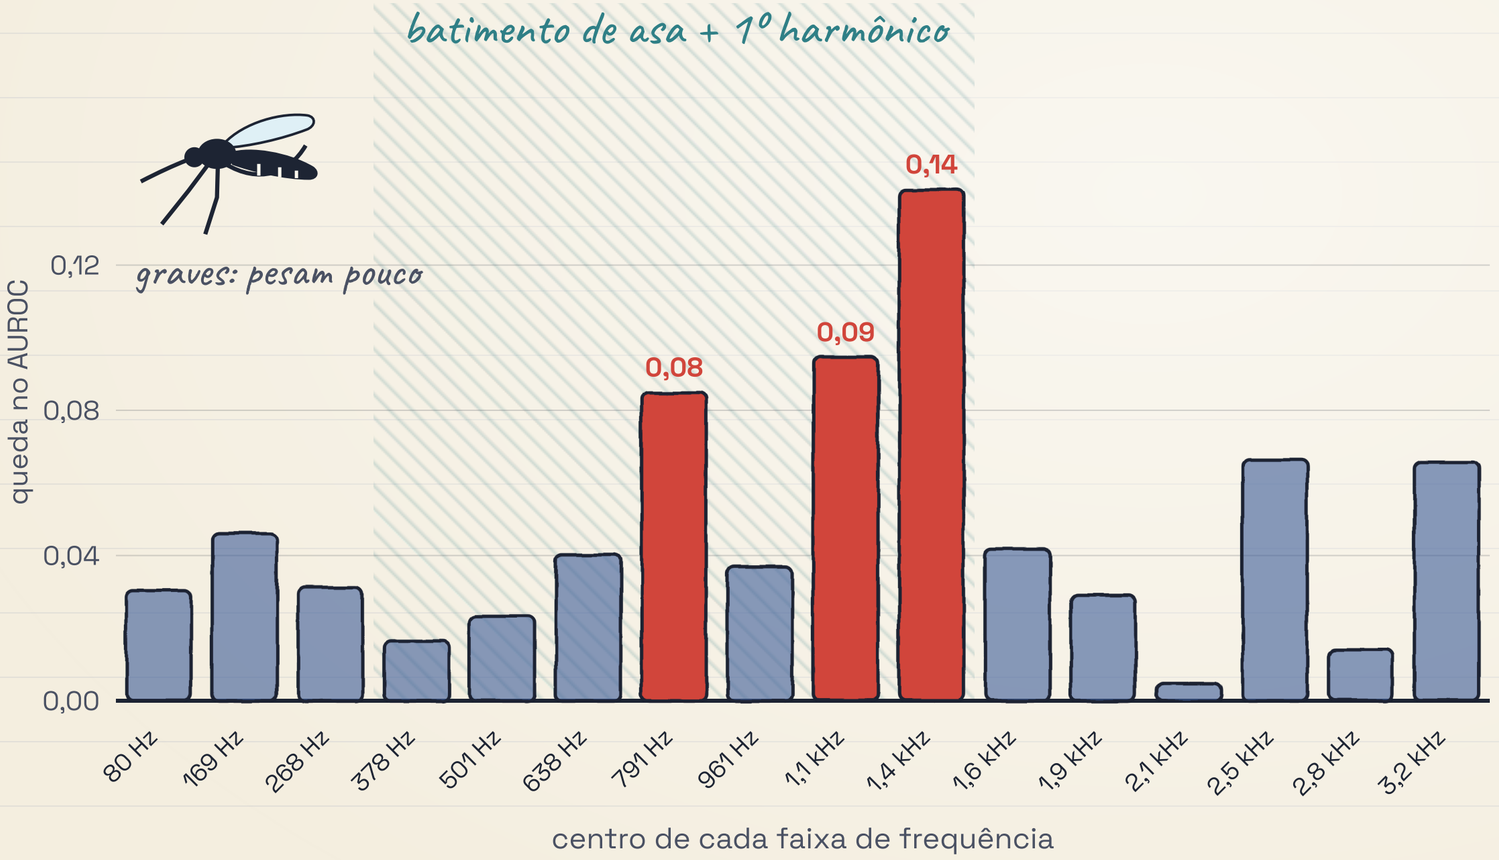
🎧 quais frequências ele usa?

🔍 ele ainda “ouve” o aparelho?



importância por permutação

Ele presta atenção no batimento de asa



embaralhar uma faixa

```
for banda in range(16):
    Z = X_teste.copy()
    c = colunas(banda)  # 5 resumos
    Z[:, c] = Z[sorteio][:, c]
    queda[banda] = auroc_base \
        - roc_auc_score(y, modelo(Z))
```

Se embaralhar uma faixa **derruba** o AUROC, o modelo depende dela. As maiores quedas estão em **0,6–1,6 kHz**: o batimento e seu primeiro harmônico. Os graves (< 300 Hz) pesam pouco.

E o aparelho? Depois da normalização, um classificador linear não consegue mais dizer de qual fonte veio um mosquito: **17%** (acaso: 20%).

IA generativa ajudando a fazer IA

Como usei assistentes de IA no código

Claude Code
Anthropic

Codex
OpenAI

Hermes
Nous Research

DeepSeek
e outros modelos

1 Eu descrevo
o objetivo, em português

2 A IA escreve
e roda o código

3 Eu confiro
números, gráficos, testes

4 Ajustamos
e repetimos

Onde ajudou muito

Código repetitivo, gráficos, ler arquivos de vários datasets, testar várias ideias rápido, revisar e documentar.

Onde precisei conferir

Se treino e prova estavam mesmo separados, se os arquivos foram lidos certo e se cada número fazia sentido.

```
assert not set(grupo[tr]) & set(grupo[te])
```

A regra

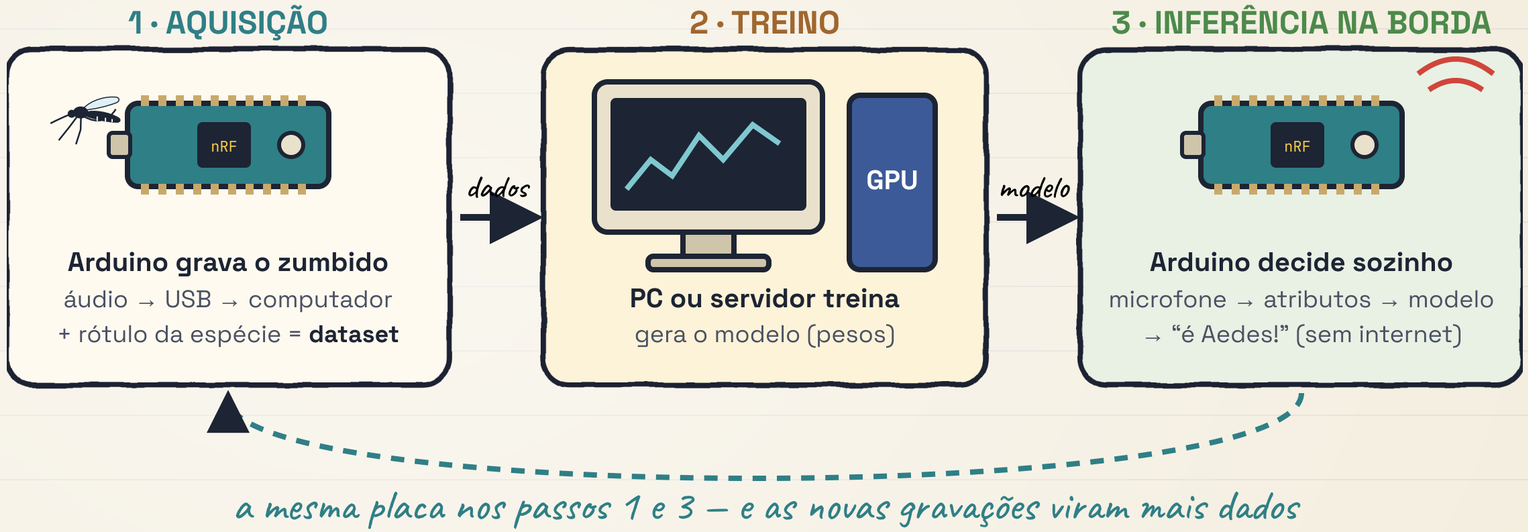
A IA acelera, mas **a responsabilidade pelo resultado é sua.** Peça para ela explicar o código e rode testes que poderiam dar errado.

IA na eletrônica

A mesma placa, dois papéis



o protótipo: a placa num pote-armadilha



Arduino Nano 33 BLE Sense

⚙️ **nRF52840**: ARM **Cortex-M4F** a **64 MHz**, com FPU (contas com vírgula em hardware)
🧠 **256 KB** de RAM · **1 MB** de flash para o programa e o modelo
🎤 microfone **MEMS digital** (PDM) já na placa
📡 **Bluetooth LE** · 🔋 consumo baixo, roda com bateria

Treinar é pesado → PC / servidor

Passa por **milhares de exemplos, dezenas de vezes**, calculando erros e corrigindo pesos. Precisa de GB de memória e, de preferência, GPU. Leva minutos ou horas.

Inferir é leve → microcontrolador

Só **uma gravação por vez** e só a "ida" do modelo (somas e multiplicações). Ex.: a MLP do slide 9 tem 18.689 pesos ≈ **73 KB** e cabe no 1 MB de flash.

próximos passos

Receita para um teste de verdade

- [ ] **Controles pareados:** Aedes *e* outras espécies gravados no **mesmo aparelho, setup e dia** — em vários aparelhos e locais.
- [ ] **Ruído in situ** dos ambientes reais, no lugar de ESC-50/Pete.
- [ ] **Mais fontes de Aedes:** o modelo só viu Aedes de dois datasets e ainda não reconhece Aedes de aparelhos novos.
- [ ] **Um teste cego único**, numa campanha nova, com o protocolo congelado **antes** da coleta.



conclusão

O que aprendemos ouvindo mosquitos

1

Dados primeiro, depois o modelo: os ajustes de dados deram o maior salto; comparar **9 modelos** na mesma prova levou à **SVM**.

2

Prova honesta: validar por grupo e aparelho. Resultado: **82% de precisão**, AUROC **0,86**; Aedes × Culex no mesmo aparelho: **0,87**.

3

Interpretabilidade: o modelo se apoia na faixa do **batimento de asa (0,6–1,6 kHz)**, não no aparelho.

Obrigado!

perguntas? bzzz...



Luiz Eduardo do Nascimento Ciarallo · `mosquito-wingbeat`