

Classificação acústica de mosquitos

Relatório técnico de métodos, resultados, explicabilidade e comparação com a literatura

Emitido em 29/09/2026. Execução analisada: 2026-09-29. Projeto: mosquito-wingbeat. Idioma: português.

Resumo executivo

O estudo reúne a leitura de três artigos, o download completo de um acervo de celulares e a comparação de oito classificadores. O benchmark principal inclui **20 espécies, 23.877 janelas de um segundo e 569 grupos**. As janelas de um mesmo grupo são reservadas juntas na avaliação.

A atualização melhorou o macro recall por grupo de 68,3% para **79,4% com boosting e contraste/dinâmica**, com **58,5% de acurácia balanceada por janela**. As CNNs e MLPs próprias também foram comparadas. A reanálise é exploratória e usa o mesmo corpus.

Para Arduino, foi implementada uma rede de 16 unidades com frontend incremental e sketch compilado para Nano 33 BLE Sense. No modo padrão, detectou 72,6% dos trechos positivos e marcou 29,2% dos trechos de ruído como candidatos. O sistema ainda erraria bastante; não foi testado numa placa física.

Questão	Conclusão sustentada
Outros métodos melhoraram a classificação?	Sim. Boosting + contraste teve 79,4% de macro recall por grupo; a comparação inicial está preservada.
Houve comparação com redes neurais?	Sim. CNNs, MLP de espécies e rede binária de 16 unidades para Arduino.
Existe explicabilidade?	Parcial: sinais, erros, sensibilidade e permutação de famílias no detector compacto.
O estudo superou os artigos?	Superioridade não demonstrada. Dados, métricas e protocolos diferem.

Este documento sintetiza experimentos já executados. A geração do relatório não treinou novos modelos; recalculou as métricas salvas para conferir a consistência dos números.

Seções 1-11: análise inicial de referência. Seções 12-15: melhorias executadas e protótipo Arduino.

Repositório: [Lciarallo/mosquito-wingbeat](#).

1. Dados, origem e auditoria

O corpus principal corresponde ao DOI **10.5061/dryad.98d7s**, associado ao trabalho de Mukundarajan et al. [1]. Foram baixados os 20 arquivos RAR completos. As rotas automáticas do Dryad recusaram o download; foi utilizado o espelho Zenodo 4964774 do mesmo DOI. Nomes, tamanhos e MD5 foram comparados com os metadados oficiais Dryad; também foram calculados SHA-256 [2].

Item	Valor verificado
Arquivos compactados	20 de 20 íntegros
Volume compactado	1.232.964.187 bytes (1,233 GB decimais)
Arquivos inventariados	1.537
Arquivos candidatos após auditoria	820
Janelas analisadas, incluindo ruído	24.405
Benchmark de espécies	23.877 janelas / 569 grupos
Classe de ruído	528 janelas / 44 grupos de fontes

Regras de exclusão de arquivos

Categoria	Arquivos
Incluídos como candidatos	820
A. sierrensis fora do recorte curado / cópias	326
Original comprimido com WAV correspondente	203
Duplicatas exatas	64
Arquivos sem áudio	63
Áudio com duração menor que 1 s	50
Recortes derivados sem relação suficientemente mapeada	9
Conteúdo idêntico com rótulos conflitantes	2

Na etapa de janelas, 67 trechos duplicados ou conflitantes foram removidos e foi identificada uma forma de onda com rótulos conflitantes. Grupos com formas de onda idênticas verificáveis foram conectados antes da divisão. As regras reduzem repetições conhecidas, sem garantir independência entre indivíduo, colônia ou sessão.

Ruídos complementares vieram do repositório dos autores TinyML [3], com commit e SHA-256 fixados. Os rótulos de espécie vêm do acervo; não houve anotação independente da atividade de mosquito em cada segundo. Arquivos e rótulos de ruído também podem ocorrer no corpus original.

2. Pré-processamento e representações

A preparação padroniza formatos e escalas, preservando uma faixa espectral compatível com gravações antigas a 8 kHz. Reamostrar para 16 kHz não cria informação acima da frequência originalmente capturada. O processo não aplica um algoritmo avançado de remoção de ruído.

Etapa	Implementação
Leitura / conversão	SoundFile; ffmpeg como alternativa para formatos não decodificados diretamente.
Canais e taxa	Média dos canais para mono; reamostragem polifásica com antialiasing quando necessário, alvo 16 kHz.
Segmentação	Janelas de 1 s sem sobreposição; até 60 por arquivo, distribuídas ao longo da gravação.
Amplitude	Remoção da média (DC) e normalização RMS; descarte de janelas praticamente silenciosas.
Integridade	Verificação de valores finitos, hashes e relações de repetição verificáveis.

Características extraídas

Representação	Informação utilizada
MFCC	Média e desvio de 13 coeficientes: 26 características da distribuição espectral.
PSD de Welch	Potência em escala logarítmica; 77 posições de 150 a 3.950 Hz, passo de 50 Hz.
Frequência / harmônicos	Histogramas de picos de 200 a 900 Hz; mediana, dispersão, quantis e escore harmônico.
Resumo espectral	Centroide, planicidade e entropia, além das estimativas de frequência.
Espectrograma Mel	40 bandas entre 100 e 3.900 Hz; FFT de 512 amostras e avanço de 256 (32/16 ms).

A representação combinada contém 112 características. A estimativa chamada F0 no código é uma aproximação baseada em picos/harmônicos; não constitui uma medição independente da frequência fundamental física em todo trecho.

O ganho apresentado adiante pertence à combinação entre representação, modelo e protocolo. Não foi feita uma ablação controlada para medir separadamente o efeito de normalização, remoção de DC, faixa espectral ou cada família de características.

3. Avaliação e definição das métricas

A avaliação principal usa três dobras estratificadas na tabela de grupos, com todas as espécies presentes em treino e teste. Grupos são definidos por hashes/relações de conteúdo verificáveis; trechos das fontes de ruído ficam juntos. São verificadas as separações por grupo e por forma de onda idêntica. Isso não equivale a reservar automaticamente toda uma colônia ou população.

- As previsões fora da dobra são reunidas para calcular os resultados finais; as janelas de teste não treinam seu modelo.
- Padronização das características dos modelos lineares é ajustada somente no treino.
- Pesos por espécie e grupo reduzem a dominância de classes frequentes e gravações longas. Nas CNNs, amostragem ponderada implementa esse balanceamento.
- As CNNs reservam grupos de validação dentro do treino externo e selecionam checkpoints pela perda de validação, com até 25 épocas e paciência de 5.
- A semente é 42. As solicitações de determinismo não garantem identidade bit a bit em todos os kernels GPU.

Métrica	Definição e interpretação
Acurácia geral por janela	Fração de trechos corretamente classificados; pode ser dominada por classes mais frequentes.
Acurácia balanceada por janela	Média do recall das espécies, dando peso igual a cada espécie.
Macro F1 por janela	Média do F1 das espécies, combinando precisão e recall.
Macro recall por grupo	Média dos escores das janelas em cada grupo, escolha da classe e média do recall entre espécies.
Intervalo bootstrap	1.000 reamostragens de grupos dentro das espécies; intervalo percentil de 95%, descritivo e condicionado às previsões salvas.

Agregar várias janelas pode melhorar o resultado por grupo. Portanto, 68,3% por grupo não significa 68,3% de acertos em todos os segundos de áudio. Os intervalos não incorporam toda a incerteza de seleção de modelo, repetição do treino ou coleta de novas populações.

Há uma comparação exploratória entre oito métodos, sem teste pareado de significância das diferenças e sem busca exaustiva de hiperparâmetros. Escolher o maior resultado observado não fornece uma estimativa imparcial para um produto futuro.

4. Resultados iniciais para 20 espécies

Método	Acurácia geral	Balanceada / janela	Macro F1	Recall / grupo
Classe majoritária	11,0%	4,9%	1,8%	5,0%
F0: soma de densidades	20,3%	32,7%	19,9%	42,9%
F0: log-verossimilhança	29,8%	41,8%	30,6%	65,9%
PSD + SVM	27,5%	41,5%	27,8%	60,8%
MFCC + regressão logística	34,0%	47,9%	38,1%	64,0%
MFCC/PSD/F0 + ExtraTrees	41,2%	48,9%	45,6%	68,3%
CNN1D compacta	20,6%	35,8%	23,3%	43,0%
CNN2D + ruído real	25,6%	40,8%	28,7%	51,8%

ExtraTrees teve **41,2% de acurácia geral**, 48,9% de acurácia balanceada por janela e 68,3% de macro recall por grupo. Esses valores representam três métricas diferentes e devem ser informados com seus nomes.

Em relação ao melhor método baseado somente em frequência (log-verossimilhança), o ganho observado foi de **7,1 pontos percentuais por janela** e **2,4 por grupo**. A diferença por grupo é modesta e não recebeu um teste inferencial específico.




Figura 1. Macro recall por grupo. Barras de erro: intervalos bootstrap descritivos de 95%.

Fonte: results/species_metrics.csv e previsões fora da dobra. Os tempos de treinamento e intervalos de todos os métodos estão no CSV. Esta geração do relatório reutiliza os resultados registrados.

5. Redes neurais e tarefa TinyML

Foram comparadas duas arquiteturas compactas próprias para 20 espécies. Ambas recebem um espectrograma Mel calculado a partir do sinal; a CNN1D faz convoluções ao longo do tempo usando as bandas como canais. A CNN2D opera no plano tempo-frequência. Não foram reproduzidas as redes completas DenseNet121, EON ou os pesos dos artigos.

Rede	Arquitetura e treinamento
CNN1D	Conv1D com 24/32 filtros, pooling, pooling global, dropout 0,5 e camada de saída.
CNN2D	Conv2D com 16/24 filtros, pooling, pooling adaptativo 4 x 4 e camada densa de 96 unidades.
Treino	Adam, LR 0,001, batch 128; no máximo 25 épocas; seleção por validação interna.
Ruído no treino	Na CNN2D e CNN TinyML: mistura em cerca de 50% dos exemplos, SNR sorteado entre 5 e 25 dB, somente fontes de treino.

No benchmark principal, ExtraTrees superou numericamente as CNNs implementadas. O resultado vale para estas arquiteturas, representações e orçamento de treinamento; não estabelece superioridade geral de árvores sobre redes neurais.

Tarefa própria de quatro classes

As classes são *Aedes aegypti*, *Aedes albopictus*, outros mosquitos e ruído. Foram usados 24.405 trechos e 613 grupos, incluindo 44 grupos de ruído. A seleção é mais ampla que a do artigo TinyML e as divisões por grupo são próprias.




Figura 2. Confusão por classe na tarefa TinyML própria, normalizada pela classe verdadeira.

6. Generalização entre aparelhos e ruído

O teste entre aparelhos reserva um celular inferido das pastas e treina nos demais, com ExtraTrees. São consideradas espécies presentes no teste e com suporte de treino suficiente. Como as classes mudam entre testes, os percentuais não formam um ranking de aparelhos.

Aparelho reservado	Classes	Grupos	Recall / grupo
Huawei866C	7	53	22,7%
Nexus	12	70	19,9%
Nokia5235	7	40	47,5%
Nokia6555B	7	33	41,9%
T209	13	91	20,5%
Xperia	15	59	31,5%
iPhone	2	11	100,0%
iPhone4S	9	75	27,8%
iPhone6	8	45	49,6%

Nos testes com pelo menos sete classes, o macro recall por grupo variou de 19,9% a 49,6%. O resultado de 100% no iPhone envolve apenas duas classes e 11 grupos, constituindo outra tarefa. A associação entre aparelho e classe limita a interpretação biológica dos ganhos.

Um diagnóstico sem áudio, usando somente aparelho e taxa de amostragem declarada, obteve **23,5% de acurácia balanceada por janela**, frente a cerca de 5% da classe majoritária. Isso evidencia associação entre coleta e rótulos; não mede quanto cada modelo acústico depende desse fator.




Figura 3. Teste de ruído em 160 janelas balanceadas por dobra (480 por condição), com fontes reais reservadas e ruído gaussiano. Médias das três dobras.

SNR de 0 dB corresponde a potências semelhantes de sinal e ruído adicionado. Nessa condição com ruído real, ExtraTrees obteve 21,0% e CNN2D 23,1% de acurácia balanceada. A pequena vantagem da CNN nessa sonda não foi testada estatisticamente; com ruído gaussiano, a ordem se inverte.

7. Explicabilidade: evidências e lacunas

A explicabilidade implementada é **parcial e predominantemente descritiva**. Há visualização dos sinais, espectros e espectrogramas; sobreposição de distribuições de frequência; matrizes de confusão; e testes de sensibilidade a ruído e aparelho. Essas análises ajudam a entender os erros e os limites do sistema.

Análise disponível	O que permite concluir
Espectros / Mel / picos	Mostram componentes presentes no sinal e variabilidade entre trechos, sem identificar sua causa biológica.
Sobreposição de frequências	Identifica semelhanças descritivas entre distribuições. A medida Bhattacharyya usa todas as gravações e não entra no treino.
Matrizes de confusão	Mostram espécies confundidas em previsões fora da dobra, sem explicar a característica responsável.
Ruído e aparelho	Revelam sensibilidade e associações de coleta; não são atribuições causais das decisões.

Exemplos de erros por grupo do ExtraTrees

Espécie verdadeira	Predição	Grupos
Anopheles gambiae	Anopheles stephensi	20
Anopheles freeborni	Anopheles albimanus	12
Anopheles gambiae	Aedes aegypti	12
Anopheles farauti	Anopheles stephensi	11
Aedes sierrensis	Culiseta incidens	10
Anopheles dirus	Anopheles stephensi	10

A tabela lista as maiores contagens de erros; espécies com mais grupos podem aparecer mais vezes. Não se trata de ranking normalizado de dificuldade. Os rótulos e a agregação seguem o protocolo de avaliação do acervo.

Na etapa inicial, não havia SHAP, LIME, importância por permutação ou Grad-CAM. **Esta atualização acrescenta permutação de famílias para o detector compacto (seção 14).** Continuam ausentes SHAP/Grad-CAM e avaliação de fidelidade de uma explicação local; não são demonstrados mecanismos biológicos causais.

Uma próxima etapa pode avaliar importância agrupada das famílias MFCC/PSD/frequência em dados reservados, ablações controladas e mapas de relevância das CNNs, com testes de estabilidade. Essas propostas são trabalho futuro.

8. Quantização INT8 e rejeição por escore

A exportação compacta usa a regressão logística de 20 espécies com 26 características MFCC. Os pesos são INT8, os produtos acumulam em INT32 e escalas/vieses usam ponto flutuante. É uma quantização do classificador linear, não da CNN nem do frontend completo.

Versão	Acurácia geral	Balanceada / janela	Macro F1
Logística original (float)	34,0%	47,942%	38,1%
Pesos INT8 / acumulador INT32	33,9%	47,933%	38,1%

O payload numérico por dobra tem **892 bytes**. A concordância das previsões float/INT8 foi **97,75%**. O código C da dobra 0 foi compilado e coincidiu com o Python em **400/400** entradas de teste. Esse teste valida a equivalência numérica da amostra, sem medir desempenho no microcontrolador.

Os 892 bytes excluem cálculo de MFCC, firmware, runtime, buffers e RAM. Não houve medição de flash total, latência, energia ou bateria. Portanto, o valor não é diretamente comparável à memória de um pipeline EON do artigo TinyML.

Abstenção exploratória da regressão logística

Limiar do escore	Cobertura	Trechos aceitos	Acurácia nos aceitos
0,0	100,0%	23.877	34,0%
0,3	64,1%	15.297	41,6%
0,5	29,9%	7.136	54,4%
0,7	16,0%	3.813	64,5%
0,9	7,2%	1.727	75,7%

Escore maiores selecionam menos trechos e aumentam a acurácia geral nos aceitos. No limiar 0,9, a cobertura é apenas 7,2%. O resultado não é desempenho sobre todo o acervo. Os escores não foram calibrados e não houve conjunto desconhecido externo para validar rejeição de novas espécies ou ruídos. Os limiares não são recomendações de produção.

9. Comparação com os estudos publicados

Os resultados dos artigos e os resultados locais respondem a perguntas diferentes. Uma porcentagem maior com outra unidade de avaliação não comprova superioridade. A comparação abaixo foi conferida nos PDFs consultados, mantendo o contexto das métricas.

Trabalho	Resultado publicado	Diferença relevante
Mukundarajan et al., 2017 [1]	Cerca de 35% sem localização e 65% com informação geográfica, média das espécies no protocolo do artigo.	Referências curadas de frequência de fêmeas e filtro geográfico. A avaliação local usa janelas/grupos próprios e não reproduz a matriz de países.
Altayeb et al., 2022 [3]	93,8% de acurácia geral de teste em quatro classes.	Subseleção própria de gravações, segmentação sobreposta, frontend e CNN/EON diferentes. A tarefa local usa mais fontes e separação por grupos.
Fanioudakis et al., 2018 [4]	96% de acurácia com DenseNet121, seis espécies e holdout aleatório de 20% dos eventos.	Outro corpus: 279.566 eventos ópticos a 8 kHz, não gravações de microfone Dryad. Esse dataset não foi baixado nem treinado aqui.

O que foi demonstrado

No protocolo local, ExtraTrees apresentou melhor resultado observado que os métodos de frequência, SVM, regressão logística e CNNs compactas testados. Há evidência de melhoria da classificação dentro dessa comparação exploratória.

O que ainda precisa ser demonstrado

Não há uma reprodução dos três protocolos originais, um teste no corpus óptico, uma equivalência com a rede Edge Impulse ou um teste estatístico pareado de superioridade. O resultado de 68,3% por grupo não deve ser apresentado como superação dos 65%, 93,8% ou 96% publicados.

MosquitoSong+ [5] motivou o uso de ruído real no treino e o teste com fontes reservadas. A extensão local usa outra arquitetura, tarefa e acervo; não reproduz o desempenho do estudo.

10. Limitações e próximos passos

- Rótulos temporais fracos: a espécie no arquivo não garante mosquito ativo em cada janela. Ruído e silêncio residual podem participar das previsões.
- Dependências não resolvidas: indivíduos, colônias, ambiente e sessões não têm identificação suficiente para garantir independência completa.
- Cobertura desigual: espécies têm diferentes números de fontes e durações; algumas estão concentradas em poucas sessões/aparelhos.
- Confundimento da coleta: aparelho/taxa de amostragem já predizem parte dos rótulos sem usar o áudio.
- Seleção exploratória: comparação de múltiplos modelos e poucas sementes, sem otimização abrangente, teste pareado ou validação externa independente.
- Explicabilidade incompleta: faltam atribuições de características e avaliação da fidelidade das explicações.
- Implantação não medida: exportar C não valida latência, memória total, consumo ou robustez em hardware de campo.

Plano de avanço, em ordem de prioridade

Prioridade	Trabalho futuro e critério de avaliação
1. Melhorar rótulos	Anotar atividade de mosquito e qualidade em uma amostra reservada; verificar identificação dos espécimes e exclusões.
2. Validar externamente	Reservar novas sessões, populações e aparelhos antes do treino, com metadados de sexo/temperatura quando disponíveis.
3. Isolar contribuições	Executar ablações de pré-processamento e famílias de características nas mesmas divisões; repetir sementes.
4. Explicar decisões	Importância por permutação agrupada, SHAP para árvores e Grad-CAM/occlusão para CNNs, com testes de fidelidade e estabilidade.
5. Comparar justamente	Reproduzir protocolos dos artigos e comparar os mesmos exemplos/métricas; usar teste pareado por unidade independente.
6. Medir implantação	Executar frontend e modelo no dispositivo alvo; medir RAM/flash, latência, energia e rejeição de classes desconhecidas.

Na etapa inicial, ExtraTrees foi o melhor entre os oito métodos implementados. As extensões das seções 12-15 melhoraram o resultado local e acrescentaram um protótipo Arduino. Transferência e ruído continuam impondo limitações antes de uso em campo.

11. Reprodutibilidade, auditoria e referências

A execução registrada contém **53 células, 27 células de código executadas e 0 erros**. A última execução levou 66,3 s, reutilizando caches e checkpoints de CNN quando as assinaturas coincidiram; esse tempo não é o treinamento completo do projeto.

Ambiente: Python 3.14.7; NumPy 2.5.3; SciPy 1.17.1; scikit-learn 1.8.0; PyTorch 2.12.0+rocm7.2; GPU AMD Radeon RX 9070 XT. O erro absoluto máximo entre os frontends SciPy/Torch foi 8.34e-07, abaixo do limite de 1e-4.

A geração deste documento recalculou acurácia geral, acurácia balanceada e macro F1 dos oito classificadores a partir das probabilidades fora da dobra e conferiu macro recall nas previsões por grupo, com tolerância de 1e-10. Também verificou a consistência das dobras por grupo e por hash de forma de onda. Hashes dos insumos e saídas estão em `reports/report_manifest.json`.

Para reproduzir: instalar `requirements.txt`, seguir `README.md` e executar o notebook. Para gerar somente o relatório a partir dos resultados existentes: instalar `requirements-report.txt` e executar `build_report.py`. A máquina precisa de `fontconfig` e da fonte `DejaVu Sans`.

Código de análise de referência: 714f61305d79. Fonte dos resultados: `results/`. Os áudios completos ficam em `data/raw/` e são baixados pelo notebook em um clone novo. Os PDFs originais dos artigos ficam somente na cópia local.

Referências

[1] Mukundarajan H. et al. (2017). Using mobile phones as acoustic sensors for high-throughput mosquito surveillance. *eLife* 6:e27854. [DOI](#).

[2] Dataset 10.5061/dryad.98d7s. [Dryad](#); [espelho Zenodo 4964774](#). Metadados e hashes: `data/`.

[3] Altayeb M., Zennaro M., Rovai M. (2022). Classifying mosquito wingbeat sound using TinyML. *GoodIT*, 132-137. [DOI](#); [dados/código](#).

[4] Fanioudakis E., Geismar M., Potamitis I. (2018). Mosquito wingbeat analysis and classification using deep learning. *EUSIPCO*, 2410-2414. [DOI](#).

[5] Supratak A. et al. (2024). MosquitoSong+: A noise-robust deep learning model for mosquito classification from wingbeat sounds. *PLOS ONE* 19:e0310121. [DOI](#).

[6] Documentação dos métodos: [SciPy resample_poly](#), [scikit-learn avaliação](#), [PyTorch](#).

Licenças e direitos: o dataset Dryad/Zenodo declara CC0; ruídos e artigos mantêm os termos de suas fontes. O relatório publica a análise e as citações, sem reproduzir os textos integrais dos artigos.

12. Melhorias executadas para 20 espécies

Foram mantidas as mesmas 23.877 janelas, 569 grupos e três dobras externas. A extensão acrescenta 181 características: contraste espectral local em 75 frequências (média/desvio), dinâmica dos MFCC e rastreamento de picos. Árvores, boosting e MLP usam 293 entradas; SVM RBF usa as 112 originais. Mudam representação, modelo e hiperparâmetros; o ganho não foi isolado por ablação de cada componente.

Método	Geral / janela	Balanceada / janela	Recall / grupo
ExtraTrees inicial	41,2%	48,9%	68,3%
SVM RBF	46,1%	55,6%	76,7%
ExtraTrees + contraste	47,7%	53,8%	72,8%
Boosting + contraste	52,7%	58,5%	79,4%
MLP + contraste	40,7%	51,6%	72,8%
Ensemble	50,7%	59,0%	77,9%

O boosting obteve 52,7% de acurácia geral e 79,4% de macro recall por grupo, ganho de **11,2 pontos percentuais por grupo** sobre ExtraTrees inicial. O ensemble teve a maior acurácia balanceada por janela (59,0%), mas macro recall por grupo inferior ao boosting.




Figura 4. Etapa inicial e novos métodos nas mesmas dobras. São métricas diferentes, não taxas de detecção de mosquito.

Bootstrap pareado: o intervalo descritivo do ganho de macro recall por grupo do boosting foi 8,9 a 13,6 pontos percentuais, 2.000 reamostragens dentro das espécies. É condicionado às previsões salvas, sem teste inferencial confirmatório, reotimização ou validação externa. A análise é adaptativa sobre o corpus já utilizado; não estabelece superioridade sobre os artigos.

A nova MLP 293-128-64-20 teve seleção por perda em grupos internos, até 70 épocas/paciência 10, e ficou abaixo do boosting. Comparações neurais incluem essa MLP e as CNNs da etapa inicial.

13. Detecção binária e erros do aparelho

Para a intenção de detectar sons em Arduino, foi criada uma tarefa binária independente da identificação de espécie. O frontend incremental usa Hann/FFT de 512 amostras a 16 kHz, 31 frames por decisão (0,992 s) e 68 características: energia relativa em 31 bandas, dispersão temporal, flatness e pico de 219-875 Hz. Não armazena um segundo inteiro nem usa normalização dependente de áudio futuro.

Logística, árvore, floresta e rede de 16 unidades foram comparadas. A seleção usa ROC AUC ponderada por fonte numa divisão interna de grupos, separada da calibração. A rede foi escolhida nas três dobras; número de épocas e padronização também respeitam essas divisões. As saídas são calibradas com pesos iguais para fontes positivas/negativas (mistura 50/50), que não é a prevalência real do ambiente.

Modo	Recall positivo / janela	Falso positivo / janela	Recall / fonte	Falso positivo / fonte
Balanceado 0,5	82,7%	35,2%	81,0%	21,8%
Calibração FPR 5%	48,9%	20,3%	48,3%	9,2%
Calibração FPR 10%	72,6%	29,2%	70,9%	15,9%

Sim, o aparelho ainda erraria bastante: no modo moderado padrão, perderia 27,4% dos trechos positivos e marcaria 29,2% dos trechos de ruído como candidatos antes da confirmação. Há 23.877 trechos positivos de 569 fontes e 528 trechos negativos de 44 fontes. Os rótulos são por arquivo, sem anotação de cada mosquito ativo ou voo.

No modo padrão, intervalos bootstrap descritivos por fonte: recall 68,5%-73,3%; falsos positivos 8,9%-24,1%. As taxas por fonte dão peso igual a gravações e diferem das taxas por janela, dominadas por fontes longas.

As metas de 5%/10% na calibração não foram garantidas no teste. Na comparação no limiar 0,5, a rede aumentou recall de 75,9% (logística) para 82,7%, mas falsos positivos passaram de 33,1% para 35,2%. Isso mostra a troca entre sensibilidade e alarmes; não é uma melhora uniforme de todas as métricas. A árvore no limiar conservador não aceitou nenhum trecho.

14. Explicabilidade e ruído do detector

A atualização executou importância por permutação em cinco famílias de características: cada família é embaralhada conjuntamente, cinco repetições por dobra, nos dados de teste reservados. A métrica é a queda de ROC AUC ponderada por fonte. Relações internas da família são preservadas; as relações entre famílias podem resultar em entradas pouco usuais.




Figura 5. Sensibilidade preditiva média do detector compacto após permutar famílias. Sem atribuição causal ou intervalo inferencial.

As bandas de 1.125-4.000 Hz tiveram a maior queda média, cerca de 0,175 de ROC AUC; as bandas de 125-1.125 Hz, 0,091. Isso mostra dependência preditiva do espectro, não prova que essas bandas representam exclusivamente asas ou que eliminam o efeito do aparelho. SHAP, LIME, Grad-CAM e fidelidade de explicações locais continuam ausentes.

Confirmação temporal

A regra causal aceita duas de três janelas completas, reiniciando em lacunas ou mudança de arquivo. O corpus foi amostrado com no máximo 60 janelas por arquivo, muitas espaçadas. A comparação nos mesmos endpoints contíguos teve 18.180 trechos positivos e 244 negativos, mas só duas fontes de ruído. No modo padrão, o falso positivo por janela mudou de 44,3% para 43,9%. A confirmação não demonstrou controle confiável de ruídos persistentes; não pode ser apresentada como solução comprovada para alarmes contínuos.

Sonda com ruído real reservado

Condição	Recall dos trechos positivos
Sem ruído adicionado	70,2%
Ruído real: SNR 20 dB	67,3%
Ruído real: SNR 10 dB	58,3%
Ruído real: SNR 0 dB	40,2%

São 480 trechos, oito por espécie/dobra, com fontes de ruído exclusivas do teste. A sonda mede sensibilidade a mistura em níveis definidos; não mede desempenho em campo, distância de alcance ou alarmes por hora.

15. Firmware Arduino e avanço necessário

O sketch inclui captura PDM, fila de áudio, frontend, rede neural e confirmação, com avisos e reset quando perde amostras. O alvo inicial é Nano 33 BLE Sense / Sense Rev2, com microfone integrado. O Uno R3/Nano clássico não tem memória suficiente para este firmware; outra placa exige adaptador de captura e compilação próprios.

Verificação	Resultado / limite
Modelo compacto	68-16-1 com ReLU, 1.121 parâmetros; aproximadamente 4.504 bytes numéricos incluindo constantes.
Frontend incremental	Objeto C++ nativo: 6.420 bytes, mais buffers/componentes no sketch.
Compilação Nano 33 BLE	CLI 1.5.1/core 4.6.0; 100.832 bytes de programa / 59.584 bytes globais.
Equivalência PCM-C++/Python	532/532 decisões iguais; maior erro de característica $3.48e-05$, de escore $8.72e-06$.
Lógica de confirmação	Testes causais e reset por lacunas passaram. Isso não comprova benefício em campo.
Placa física	Sem upload, teste do microfone, latência, consumo, bateria ou pico de RAM medidos.

A compilação informa programa e RAM estática, excluindo pico de pilha/heap. O teste nativo usa 400 trechos positivos e todos os 132 negativos de teste da dobra 0. A exportação padrão é dessa dobra; o benchmark agregado aplica cada modelo à sua própria dobra. Não houve retreino e validação de um modelo de produção.

A primeira confirmação exige três janelas completas, ou 2,976 s de observação, além do tempo computacional não medido. Passagens muito curtas podem ser perdidas; não foi validada a detecção de cada voo isolado.

Para reduzir erros de forma verificável

- Coletar áudio com a placa e microfone escolhidos no local de uso, incluindo distância, ganho e qualidade de captura.
- Anotar mosquito realmente ativo/inativo e gravar horas sem mosquito com ventilador, fala, chuva, máquinas e outros insetos.
- Reservar dias e locais inteiros antes do ajuste; treinar com ruídos locais, recalibrar limiares e testar classes desconhecidas.
- Medir sensibilidade por evento, falsos alarmes por hora, latência e perdas de amostras no hardware. Estes resultados requerem a coleta física que ainda não existe.

Instalação e modos de operação: [firmware/README.md](#). Arquivos de auditoria: [results/arduino/](#). Documentação oficial: [Nano 33 BLE Sense Rev2](#), [Uno R3](#).